



포스코 홈페이지 문의 자동답변 AI 에이전트

포스코 서정현

2026. 04. 16



CONTENTS

01 왜 이 프로젝트를 시작했는가

연간 5,000건의 문의와 미대응 메일 문제 해결을 위한
AI 자동화 가설 설정 및 프로젝트 목표

02 가설을 데이터로 검증

과거 데이터 전수 분류를 통해 확인된
AI 처리 가능 범위와 담당자 이관 필요성 입증

03 개발 여정과 시스템 설계

수신부터 검증까지 안전한 전체 프로세스 구축과
2단계 분류 및 RAG 기반 답변 생성 파이프라인

04 12라운드 개선과 RAGAS 결과

정량적 평가 지표(RAGAS)를 활용한 반복 실험과
환각 방지, 성능 고도화를 위한 핵심 전환점

05 데모·인사이트·향후 계획

실제 메일 처리 결과 시연 및 성과 측정,
프로젝트를 통해 얻은 기술적 교훈과 발전 로드맵

왜 이 프로젝트를 시작했는가

실제 업무 문제를 AI로 해결할 수 있는지 검증하고 구현하는 프로젝트

💡 AI활용전문가 과정



연간 문의량

5,000+

연간 약 5,000건 문의 접수 → 수작업 분류·회신



미대응 메일

4,000+

연간 문의 5,000건 중 약 4,000건 미대응



반복 문의

60%+

60% 이상이 동일한 답변 반복



다국어 대응

4개국어

다국어 문의 + 고가치 문의 누락 리스크



고가치 문의 누락 리스크

중요한 문의가 묻혀 대응 지연될 수 있음

위험 요인

💡 핵심 가설

"문의 대부분은 AI가 자동 처리하거나
최소한 안전하게 선별할 수 있다"

90%+

자동 처리 가능

6.5%

담당자 필요



차단할 것 (스팸)



자동응답할 것 (채널 안내)



사람에게 넘길 것 (고가치)



문제 정의

현장 문제점 확인



가설 검증

데이터 기반 확인



운영 설계

AI 파이프라인 구축




시스템 검증

성능 및 안전성

가설을 데이터로 검증했습니다

미대응 메일 1,000건 전수 분류 결과 - AI가 처리할 수 있는 범위를 실제 데이터로 확인



618건

스팸·사칭·광고

287건

자동응답 가능

65건

고가치 문의

30건

기타 (수동 분류)

검증 방식

미대응 메일 1,000건을 AI로 전수 분류하여 각 유형별 비중과 처리 가능성을 정량적으로 분석했습니다.

정책 연결

스팸은 자동 차단, 자동응답 가능은 AI 처리, 고가치 문의는 담당자 즉시 이관으로 분기 기준을 세웠습니다.

분석 대상 (전체 문의)	1,000건
AI 자동화 가능 영역	92.4%
사람이 필요한 고가치 문의	6.5% (65건)

핵심 발견

전체 문의의 90%+는 단순 처리로 해결됩니다. AI 자동화를 통해 6.5%의 고가치 문의에만 담당자의 역량을 집중할 수 있는 환경을 확인했습니다.

한 달간의 개발 여정

문제 정의 → 데이터 검증 → 시스템 설계 → 구현 → 개선의 전 과정

과정 중심

5단계 개발 과정 AI활용전문가 과정에서 문제를 해결한 전체 여정

</> 28파일 / 6,723줄 / 17일 개발

1. 문제 정의

반복 문의, 미대응 메일, 자동화
가설 설정

연 5,000건 문의

2. 데이터 검증

미대응 1,000건 전수 분류로
자동화 가능성 확인

90%+ 처리 가능

3. 시스템 설계

수신/번역/분류/분기/검증 구조
설계

9그룹/46카테고리

4. 구현과 실험

2단계 분류, Dynamic Few-
shot, RAG 구현

3,369건 few-shot

5. 평가와 고도화

12라운드 RAGAS 평가와 파일럿
테스트

품질 개선 완료

가설에서 시작
실제 업무 문제를 AI로 해결할 수 있는지 검증

측정으로 검증
1,000건 전수 분류로 자동화 가능성 확인

실험으로 개선
12라운드 평가와 반복 개선으로 품질 향상

이번 프로젝트는 결과보다 과정이 더 중요했습니다. 문제정의 → 검증 → 구현 → 개선의 전 과정을 경험한 개발 여정이었습니다.

버전별·주차별 개발 업데이트

17일 개발 기간 동안의 버전 변화와 아키텍처 고도화 과정

🔗 4단계 개발 과정 (17일)

AI활용전문가 과정 개발 타임라인



IMAP 수신, 단일 분류기, 기본 RAG, 다국어 번역, SQLite DB 적용 첫 이메일 라이브 테스트 완료	2단계 분류 체계화, Hybrid Search 및 Reranker 도입 Dynamic Few-shot (3,369건)	RAGAS 평가, LangGraph, HyDE, Self-RAG, Opus 업그레이드 FastAPI 대시보드 / 파일럿 성공	FAISS→Chroma 전환, 피드백 루프 구축, 프롬프트 정합성 보완 레거시 정리 (17,893 → 6,723줄)
--	---	---	--




아키텍처의 진화 과정

초기에는 기능 구현(파이프라인 연결)에 집중, 이후 측정(RAGAS)과 구조화(모듈 분리, 피드백 루프)로 발전하며 운영 가능한 시스템으로 고도화

안전한 운영을 기준으로 전체 프로세스를 설계했습니다

수신 → 번역 → 분류 → 분기 → 생성·검증 → 발송의 end-to-end 구조



2단계 분류 + Dynamic Few-shot

병원 접수처처럼 2단계로 분류하고, 과거 사례를 참고해 정확도를 높였습니다

분류 시스템

2단계 분류 구조 1단계: 9개 큰 그룹 → 2단계: 46개 세부 카테고리



79.8%
그룹 정확도
↑ 5.2% 개선

95.7%
고가치 탐지율
↑ 3.1% 개선

3,369건
Few-shot 인덱스
+ 학습 데이터

운영 원칙

? 확신 낮음 → 검토 큐

고가치 → 즉시 이관

Dynamic Few-shot 적용

과거 문의 **3,369건** 중 유사 사례 **5건**을 찾아 AI에게 함께 제공
= "신입사원에게 이전 사례를 보여주는 것"

과거 답변을 참고해서 새 답변을 만듭니다

프롬프트 최적화보다 양질의 참고 자료(RAG)를 찾아주는 것이 성능에 더 결정적이었습니다.

📖 도서관 비유: 과거 답변을 찾아 새 답변을 만드는 4단계 검색 과정

HyDE → Hybrid Search → Reranker → 근거 기반 답변

STEP 01. HyDE

가상 답변 생성

질문만으로 검색하지 않고, AI 사서가 예상되는 가상의 답변을 먼저 생성해 검색어로 활용

STEP 02. Hybrid Search

의미 + 키워드 검색

벡터 유사도(의미) 검색과 BM25(정확한 키워드) 검색을 결합하여 누락 없는 1차 후보군 추출

STEP 03. Reranker

최적 후보 재정렬

추출된 후보군 중 현재 질문과 가장 문맥이 딱 맞는 상위 5개의 과거 답변을 엄선

STEP 04. Generation

근거 기반 답변 생성

엄선된 5개의 과거 자료만을 절대적 근거로 삼아 최종 답변을 생성 (환각 방지)

① 자동응답 이력 저장

AI가 생성하여 발송한 답변 내용을 시스템 DB에 자동 기록

② 담당자 수정 반영

검토 과정에서 담당자가 수정한 고품질 답변도 정답 셋으로 저장

③ 검색 벡터 DB 업데이트

누적된 답변 이력이 RAG 검색을 위한 벡터 데이터베이스에 증분 반영

④ 자가 학습 품질 향상

운영 기간이 길어질수록 유사 문의에 대한 검색/답변 품질이 자동 향상

현재 구축된 FAQ DB **2,191건**

1년 후 누적 예상치 **5,000+건**

기대 목표 근거 충실도 **70% 안정화**

🔍 운영할수록 스스로 똑똑해지는 선순환 구조 확립

12라운드 개선 과정에서 무엇을 바꿨나

측정-실험-수정의 반복 속에서 어떤 판단과 변경이 있었는지 정리

12라운드 핵심 개선 액션

무엇을, 왜 바꿨는지에 대한 의사결정 기록

■ R1~R2

검증 후처리 도입·기준선 확보

환각 발생을 차단하기 위해 생성과 별도의 검증 단계를 추가

■ R3~R5

검색/분류/생성 구조 조정

Hybrid Search, Reranker, Few-shot 적용으로 문맥 정확도 향상

■ R6~R7

답변 전략 강화

Opus, HyDE, Self-RAG 도입으로 정답률 극대화 시도

■ R8

도메인 기준 재설계

범용 기준이 아닌 실제 업무 지침에 맞게 평가 프롬프트 전면 수정

■ R10~R12

운영형 정착

모름 인정 로직 도입, 프롬프트 정합성 보완 및 피드백 반영 확립

🛡️ 검증은 생성과 별도로 설계해야...

하나의 완벽 프롬프트로 해결하려 하기보다, 답변을 생성하는 모델과 그것을 검증하는 모델의 역할 및 기준을 분리하는 것이 구조적으로 훨씬 안전했습니다.

🔍 좋은 답변보다 좋은 데이터가 먼저...

모델에게 똑똑하게 대답하라고 지시하는 것보다, 필요한 배경 지식을 누락 없이 정확하게 검색해서 넘겨주는 RAG 파이프라인 개선이 성능에 더 결정적이었습니다.

⚖️ 상용 기준 아닌 도메인 기준으로 평가해야...


"담당 부서로 문의하세요"라는 답변은 범용 AI 기준에선 불완전했지만, 실제 업무에서는 100점짜리 가이드였습니다. 평가 척도를 도메인에 맞추는 작업이 필수였습니다.

💡 다회차의 성능테스트로 인해 답변의 정확도를 올릴 수 있었고, 추후 스스로 학습하는 구성으로 인해 업무를 반복할 수록 더욱 발전해가는 시스템 완성

12라운드 RAGAS 결과와 전환점

개선이 실제 성능 변화로 어떻게 나타났는지 수치와 전환점으로 확인

결과 + 전환점



R2
Faithfulness 반등
환각 제거 **64.3%**

R6 & R7
Correctness 최고
정확성 **93.8%**

R8
Completeness 급상승
기준 재설계 **66.0%**

R12
최종 밸런스 정착
운영 기준 확정

라운드	핵심 라운드 결과 확인	Faithfulness	Relevance	Correctness	Completeness
R1	초기 성능 측정 (Baseline)	42.9%	78.6%	78.6%	14.3%
R2	Faithfulness 반등 지점	64.3%	78.6%	92.9%	21.4%
R6	Correctness 최고 지점	70.8%	77.1%	93.8%	22.9%
R7	Faithfulness 최고 지점	83.3%	75.0%	85.4%	18.8%
R8	Completeness 급상승 시작	78.0%	74.0%	84.0%	66.0%
R12	최종 성능 지표 확정	54.8%	90.5%	88.1%	90.5%

Faithfulness 54.8% — 운영에 문제없는 이유

안전 설계

환각 위험을 통제하는 3중 안전장치와 실제 운영 구조

✓ 팩트이지만 근거가 없는 내용

"스테인리스 제조 가능"처럼 사실이지만 참고 자료에 없는 정보

발생 빈도 및 위험도

대부분이 이 유형 - 의도적으로 엄격한 기준 적용

중간

i 상식적인 서술

"종합적으로 고려하여 선발"처럼 일반적인 표현

발생 빈도 및 위험도

상식적 내용이라 실제 위험은 적음

낮음

✗ 할루시네이션

"없는 스펙/가격"처럼 완전히 잘못된 정보

발생 빈도 및 위험도

극소수 - 3중 안전장치로 완벽 차단

높음

3중 안전장치 기반 운영 프레임워크

운영 리스크 최소화

채널안내형 자동 응답 (60%)

환각 위험이 가장 낮은 단순 안내만 즉시 발송

실질답변형 휴먼 인 더 루프 (40%)

정보 제공형 답변은 담당자 최종 확인 후 발송

고가치 즉시 이관 (6.5%)

비즈니스 중요도가 높은 문의로는 AI 개입 없이 전달


FAQ Knowledge Base

2,191건

운영 커버리지율 95.7%

지속적인 피드백 루프를 통한 데이터 자산화 진행 중

✓ 안전 최우선 설계: 위험한 답변이 고객에게 직접 도달할 경로를 원천 차단하여, 낮은 Faithfulness 점수에도 불구하고 실제 운영 리스크를 완벽히 통제 (추후 데이터 확보 후 업그레이드)



결과 시연 + 파일럿 테스트

[▶ 데모 & 결과](#)

실제 이메일을 통해 시스템의 동작을 검증하고 결과를 분석했습니다

1 테스트 이메일 발송



SS400 후판 견적 문의

발신자: customer@example.com

발송 완료



테스트 이메일 전달

시스템 정상 수신 확인

성공

2 AI 자동 처리



문의 자동 감지 및 분류

채널안내형으로 분류됨

완료



AI 답변 생성 및 검증

응답 정확도 검증 통과

완료

3 답변 수신 확인



POSCO 양식 HTML 답변

Gmail에서 수신 확인

수신



답변 내용 정확히 매칭

채널 안내 완료

완료

📌 파일럿 결과 요약 (실제 Gmail 11건)

5건

채널안내형 자동 회신

✓ 100%

3건

실질답변형 검토 큐

✓ 75%

1건

고가치 담당자 이관

✓ 100%

1건

스팸 차단

✓ 100%

10/10

분류 정확도

✓ 100%

30초

대응 시간

↓ 99% 감소

↔ Before / After 요약

수작업 → AI 자동
79.8% 정확도

단순 문의 처리
60% 자동화

미대응 문의
전수 처리 완료

다국어 지원
4개국어 탑재



"포석호" 키워드로 문의하면 챗봇이 직접 답변합니다!

핵심 인사이트 & 향후 계획

06 인사이트·향후 계획 · 14 / 14

한 달간의 프로젝트를 통해 얻은 교훈과 다음 단계

좋은 답변의 핵심은 참고 자료

프롬프트를 잘 쓰는 것보다 AI가 참고할 자료를 정확하게 찾아주는 것이 더 중요했습니다. 참고 자료가 없으면 자체 지식으로 보충하여 환각이 발생합니다.

업무 맞춤 평가 기준의 중요성

시스템 설계만큼 평가 기준도 중요했습니다. 범용 기준에서 도메인 맞춤 기준으로 변경한 후, 평가의 정합성과 정확도가 대폭 개선되었습니다. (18.8% → 90.5%)

모르면 '모른다'고 답하는 설계

AI가 억지로 답변을 생성하기보다, 확신이 없을 때는 '모름'을 인정하고 정확한 담당 창구나 사람에게 연결하도록 설계하는 것이 필수적이었습니다.

향후 계획 로드맵

단기 (1-2개월)

파일럿 운영 확대, 담당자 자동 전달 프로세스 구축, IT 보안 정식 승인

파일럿 확대

자동 전달

중기 (3-6개월)

FAQ DB 2,191→5,000+ 확장 축적, 의도 분류 정확도 90% 이상 목표

DB 축적

정확도 향상

장기 (6개월+)

홈페이지 API 직접 연동, 전사 그룹사 서비스 확장 및 통합

API 연동

그룹사 확장

과정 수료 소감

- 이번 과정을 통해 단순히 모델을 호출하는 것과 실제 업무형 AI 시스템을 설계하는 것은 다르다는 점을 깊이 배웠습니다.
- 데이터·검색·평가·운영정책을 유기적으로 설계해야 현업에 안전하게 적용 가능한 AI가 된다는 점이 큰 수확이었습니다.
- 신뢰할 수 있는 AI는 정답 생성에 그치지 않고, 실패를 통제하고 대응하는 구조임을 체감했습니다.



감사합니다.

Q&A

